

Note Technique : Développement et Déploiement d'un Modèle de Segmentation d'Images pour Véhicules Autonomes

1. Introduction

Contexte de la mission

L'objectif de ce projet est de développer un modèle de segmentation d'images pour les systèmes embarqués de véhicules autonomes, avec une intégration dans une application cloud déployée sur Azure.

Objectifs :

1. Comparer plusieurs architectures de modèles de segmentation (U-Net Mini, VGG16 U-Net, DilatedNet).
2. Identifier le modèle le plus performant selon des critères précis (IoU, Dice, perte de validation, temps d'entraînement).
3. Déployer une solution comprenant une API **FastAPI** et une interface **Streamlit**.
4. Présenter les résultats avec des recommandations pour une future industrialisation.

2. État de l'art

2.1 Approches classiques et modernes pour la segmentation d'images

- **Modèles CNN classiques :** U-Net, VGG16 U-Net – Reconnus pour leur efficacité dans les tâches de segmentation, notamment pour les structures à petite échelle.
- **Modèles avancés :** DilatedNet, SegFormer – Exploitent des techniques modernes comme les convolutions dilatées et les transformers pour capturer davantage de contexte global.

2.2 Références bibliographiques

- Articles scientifiques :
 1. Dilated-UNet: A Fast and Accurate Medical Image Segmentation Approach
URL : <https://arxiv.org/abs/2304.11450>
 2. U-Net: Convolutional Networks for Biomedical Image Segmentation
URL : <https://arxiv.org/abs/1505.04597>
 3. Automatic detection of lumen and media in IVUS images using U-Net with VGG16 Encoder
URL : <https://arxiv.org/abs/1806.07554>
- Blogs techniques :
 1. U-Net Image Segmentation
URL : <https://medium.com/@feitgemel/u-net-image-segmentation-how-to-segment-persons-in-images-2fd282d1005a>
 2. Dilated Convolution for Semantic Segmentation
URL : <https://towardsdatascience.com/review-dilated-convolution-semantic-segmentation-9d5a5bd768f5>

3. Présentation des différentes approches

3.1 Modèle 1 : U-Net Mini

- **Description** : Version simplifiée de U-Net, conçue pour des environnements contraints.
- **Avantages** :
 - Faible consommation de mémoire GPU.
 - Temps d'entraînement rapide.
- **Inconvénients** :
 - Moins performant pour capturer des détails fins.

3.2 Modèle 2 : VGG16 U-Net

- **Description** : Combinaison de VGG16 (encodeur) et de U-Net (décodeur).
- **Avantages** :
 - Performances élevées grâce au transfert learning.
 - Bonne généralisation sur le dataset de validation.
- **Inconvénients** :
 - Temps d'entraînement plus long.

3.3 Modèle 3 : DilatedNet

- **Description** : Exploite des convolutions dilatées pour capturer des informations contextuelles globales.
- **Avantages** :
 - Bonne capacité à capturer des relations globales.
- **Inconvénients** :
 - Perte élevée, difficulté à généraliser.

4. Comparaison des modèles

4.1 Tableau récapitulatif

Modèle	Loss Type	Val Loss	IoU	Dice	Training Time (min)
U-Net Mini	Categorical Cross-Entropy	0.462157	0.5881	0.6966	79.14
VGG16 U-Net	Combined Loss	0.411980	0.6074	0.7132	153.59
DilatedNet	Categorical Cross-Entropy	0.799034	0.3907	0.5027	138.12

4.2 Analyse comparative

- **VGG16 U-Net** : Meilleur IoU (0.607) et score Dice (0.713). Convient pour des applications nécessitant une haute précision.
- **U-Net Mini** : Bonne performance avec un temps d'entraînement réduit (79 min). Idéal pour des environnements contraints en calcul.
- **DilatedNet** : Moins performant dans ce contexte avec une IoU plus faible (0.390).

5. Contexte du dataset de test

Le dataset de test utilise un format différent (images noires avec des entiers représentant les classes), ce qui a créé un **blocage méthodologique** :

- Le format n'est pas aligné avec les données d'entraînement ou de validation.
- Sans collaboration avec l'équipe en charge des données, il n'a pas été possible de confirmer

l'exactitude d'un mapping ou la pertinence du format actuel.

Décision : L'évaluation des modèles s'est concentrée sur le dataset de validation, complétée par des visualisations exploratoires sur le dataset d'entraînement.

6. Présentation détaillée du modèle retenu : VGG16 U-Net

6.1 Architecture du modèle

1. **Encodeur :** Basé sur VGG16 pré-entraîné sur ImageNet pour extraire des caractéristiques hiérarchiques.
2. **Décodeur :** U-Net avec skip connections pour reconstruire les détails et générer des masques précis.

6.2 Caractéristiques techniques

- Entrée : Images (256x256x3).
- Sortie : Masques segmentés (256x256x8).
- Perte : Combinaison de Cross Entropy Loss et Dice Loss.
- Optimiseur : Adam avec ajustement dynamique du learning rate.

7. Résultats obtenus

7.1 Impact de la Data Augmentation

La **Data Augmentation** améliore la généralisation des modèles, en augmentant la diversité des données d'entraînement.

Référence : Springer Journal on Big Data.

URL : <https://journalofbigdata.springeropen.com/articles/10.1186/s40537-019-0197-0>

7.2 Visualisation des résultats

- Les masques segmentés produits par **VGG16 U-Net** montrent une meilleure précision sur les détails fins.
- Comparaisons qualitatives confirmées par les métriques sur le dataset de validation.

8. Déploiement sur Azure

8.1 API FastAPI

- **Fonctionnalités :** Prend en entrée une image et retourne un masque segmenté.
- **Déploiement :** Conteneurisée avec Docker, hébergée sur Azure.

8.2 Application Streamlit

- **Fonctionnalités :** Chargement d'images, interactions avec l'API FastAPI, visualisation des masques segmentés.

9. Conclusion et axes d'amélioration

Synthèse

- **Meilleur modèle** : VGG16 U-Net avec IoU (0.607) et Dice (0.713).
- **MVP déployé** : API FastAPI et interface utilisateur Streamlit sur Azure.

9.1 Mise en place d'un pipeline CI/CD

1. **Objectif** : Automatiser les tests, la construction et le déploiement des modèles via une intégration continue
2. **Étapes clés** :
 - **Construction automatique** : Utiliser **GitHub Actions** pour tester et construire les images Docker du projet et **Déploiement sur** conteneurs via **Azure Container Registry (ACR)**.

9.2 Exploration de modèles avancés

1. Étudier les architectures modernes comme **SegFormer** et **DeepLabV3**.
 - **SegFormer** : Offre une segmentation basée sur les transformers, capable de capturer efficacement le contexte global.
 - **DeepLabV3** : Exploite les convolutions atrous (dilatées) pour améliorer la segmentation des objets à différentes échelles.
 - Référence pour DeepLabV3 :
URL : <https://medium.com/towards-data-science/review-deeplabv3-atrous-convolution-semantic-segmentation-6d818bfd1d74>